Análisis de datos de producción

Energía Solar Fotovoltaica

Oscar Perpiñán Lamigueiro

Universidad Politécnica de Madrid

Planteamiento

- La **energía producida por un SFV** durante un período puede ser **estimada** a partir de la **radiación incidente** y de las **características técnicas** del sistema.
- Teniendo en cuenta el carácter estocástico de la radiación solar, la estimación de la energía que producirá un SFV durante los próximos años es un ejercicio de **predicción con incertidumbre** asociada.
- El funcionamiento de un SFV puede ser analizado tomando esta estimación como referencia (**comparación modelo-medidas**).
- En el caso de centrales FV, se pueden detectar problemas de funcionamiento comparando diferentes partes de la central (**coherencia estadística**).

Variable aleatoria y proceso estocástico

- Una **variable aleatoria** es una función que asigna un único numero real a cada resultado de un espacio muestral en un experimento.
- Un **proceso estocástico** es una variable aleatoria que evoluciona a lo largo del **tiempo** (p.ej. la radiación).

Función de densidad de probabilidad

La función de densidad de probabilidad, $f(X)$, de una variable aleatoria **asigna probabilidad** a un suceso:

$$P(a < X < b) = \int_a^b f(x)dx$$

$$P(X < b) = \int_{-\infty}^b f(x)dx$$

$$P(X > a) = \int_a^\infty f(x)dx$$

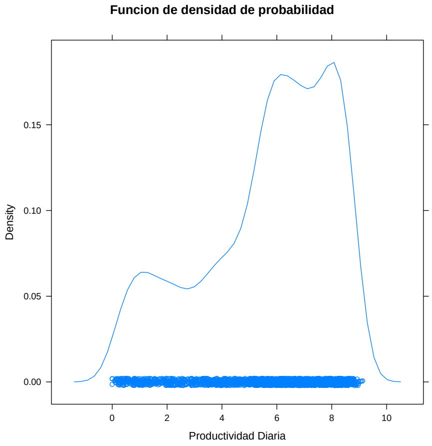

Media, varianza y desviación estándar

- La **media** de una variable aleatoria es el **centro de masas** de su función densidad de probabilidad:

$$\mu_X = \int_{-\infty}^{\infty} x \cdot f(x)dx$$

- La **varianza** de una variable aleatoria es la **media del cuadrado de las desviaciones** respecto a la media:

$$\sigma_X^2 = \int_{-\infty}^{\infty} (x - \mu_X)^2 \cdot f(x)dx$$

- La **desviación estándar** es la raiz cuadrada de la varianza: $\sigma_X = \sqrt{\sigma_X^2}$

Combinación lineal de variables aleatorias

- La **media de la suma** de varias variables aleatorias **independientes** es la suma de las medias:

$$\mu_{X_1+\ldots+X_n} = \mu_{X_1} + \ldots + \mu_{X_n}$$

- La **varianza de la *suma o resta*** de varias variables aleatorias **independientes** es la **suma** de las varianzas:

$$\sigma^2_{X_1\pm\ldots\pm X_n} = \sigma^2_{X_1} + \ldots + \sigma^2_{X_n}$$

Media y varianza de la media muestral

- Una **muestra de una población** es un conjunto de variables aleatorias independientes $(X_1 ... X_n)$.
- Si se toma una muestra de una población, la media de la muestra es otra variable aleatoria (que es una suma de variables aleatorias)

$$\overline{X} = \frac{1}{i = n} \sum_{n} X_i$$

Media y varianza de la media muestral

Sea una población cuya media es μ y su varianza es σ^2:

- La **media de la media muestral** es la media poblacional:

$$\mu_{\overline{X}} = \frac{1}{i = n} \sum_{n} \mu_{X_i} = \mu$$

- La **varianza de la media muestral** es la varianza poblacional dividido por el número de muestras.

$$\sigma^2_{\overline{X}} = \sigma^2_{\frac{1}{n}X_1} + ... + \sigma^2_{\frac{1}{n}X_n} = \frac{\sigma^2}{N}$$

Por tanto, una forma de **reducir la incertidumbre** es realizar la **medida en repetidas ocasiones**.

Mediana y cuartiles

- La **mediana** divide el conjunto de valores de la variable en **dos mitades** iguales (divide el area encerrada por la función densidad de probabilidad en dos partes iguales).
- Los **cuartiles** dividen este area en **cuatro** partes iguales.
- El area encerrada entre cada par de cuartiles es igual al 25% del total.
- La **mediana** es el **segundo cuartil**.
- La **distancia intercuartil** (definida entre los cuartiles 1 y 3) es una **medida de la dispersión** de la variable.

Función de Densidad de Probabilidad

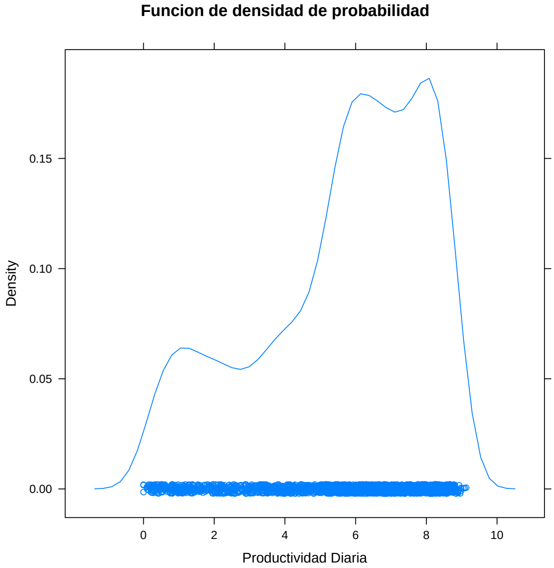

Histograma

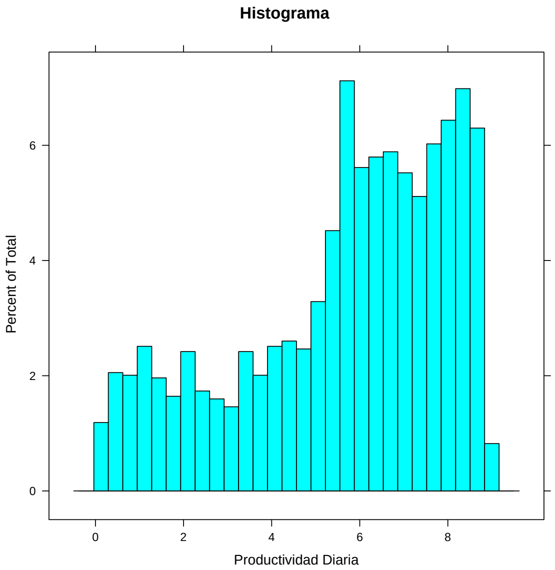

Gráficos boxplot

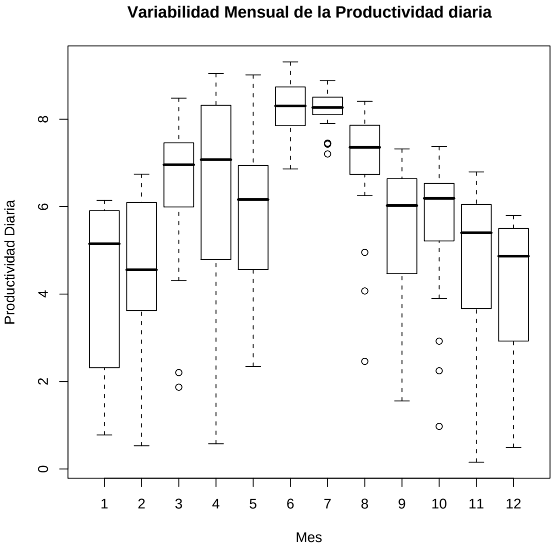

Gráficos de dispersión

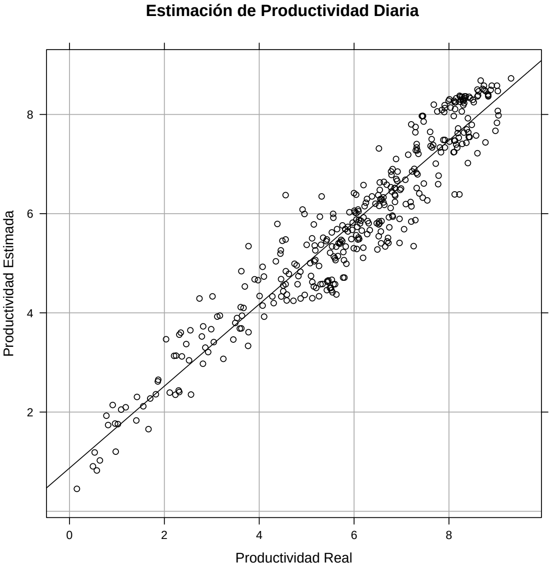

Matrices de gráficos de dispersión

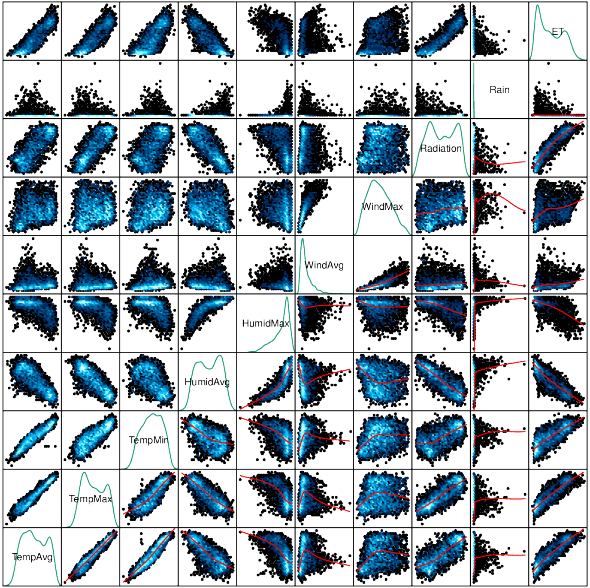

Gráficos Fotovoltaicos*

- $Y_f \sim Y_r$ (valores diarios e intradiarios)
  Relación lineal creciente. Detección de sombreado, defectos en cableado DC y AC, fallos o limitación del inversor.
- $Y_a \sim Y_r$ (valores diarios e intradiarios)
  Relación lineal creciente. Detección de sombreado o defectos en cableado DC.
- $pr \sim T_c$ (valores intradiarios)
  Relación lineal decreciente. Detección de sombreado, degradación, o puntos calientes.
- $(T_c - T_a) \sim y_r$ (valores intradiarios)
  Relación lineal creciente. Detección de problemas de disipación de calor.
- $V_G \sim T_c$ (valores intradiarios)
  Relación lineal decreciente. Detección de problemas en el MPPT, limitación del inversor, diodos de bypass.

*Más ejemplos en el informe «Analytical Monitoring of Grid-connected Photovoltaic Systems» de la Task 13 del IEA-PVPS.

Desviación entre modelo y observación

- Sea O el conjunto de observaciones (medidas) de una variable aleatoria.

$$\mathbf{O} = \{o_1 \ldots o_n\}$$

- Sea M el conjunto de resultados de un modelo que aproxima el comportamiento de la variable medida.

$$\mathbf{M} = \{m_1 \ldots m_n\}$$

- La desviación entre modelo y observación es:

$$\mathbf{D} = \mathbf{M} - \mathbf{O} = \{(m_1 - o_1) \ldots (m_n - o_n)\} = \{d_1 \ldots d_n\}$$

Exactitud (*bias*) y Precisión (*variance*)

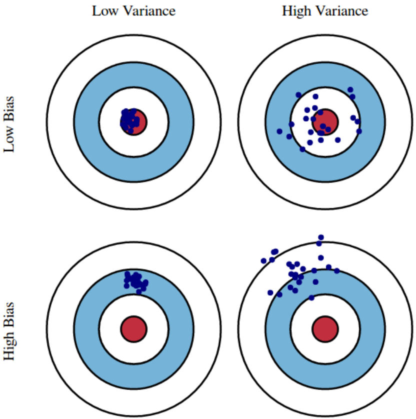

Fig. 1 Graphical illustration of bias and variance.

http://scott.fortmann-roe.com/docs/BiasVariance.html

Estimadores frecuentes: MBD y RMSD

- Mean Bias Difference (MBD), diferencia media (indica si el modelo sobreestima o subestima):

$$MBE = \overline{\mathbf{D}} = \overline{\mathbf{M}} - \overline{\mathbf{O}} = \frac{1}{n}\sum_{i=1}^{n}(m_i - o_i)$$

- Root Mean Square Difference (RMSD), diferencia cuadrático media:

$$RMSD = \left(\frac{1}{n}\sum_{i=1}^{n} d_i^2\right)^{1/2} = \left(\frac{1}{n}\sum_{i=1}^{n}(m_i - o_i)^2\right)^{1/2}$$

Estimadores frecuentes: MBE y RMSD

El RMSD agrega información del promedio y la varianza de la diferencia:

$$RMSD^2 = \overline{\mathbf{D}}^2 + \sigma_{\mathbf{D}}^2$$

donde la varianza de la diferencia (unbiased RMSD) se calcula:

$$\sigma_{\mathbf{D}}^2 = \frac{1}{n}\sum_{i=1}^{n}(d_i - \overline{\mathbf{D}})^2$$

Otros estimadores: MAD

- Mean Absolute Deviation (MAD):

$$MAD = \frac{1}{n}\sum_{i=1}^{n}|d_i| = \frac{1}{n}\sum_{i=1}^{n}|m_i - o_i|$$

- El RMSD no es robusto (un error puntual puede distorsionar el estimador) y depende del número de muestras:

$$MAD \leq RMSD \leq n^{1/2}MAD$$

Otros estimadores: t y d

- t de Student (valores pequeños indican buen comportamiento del modelo)
  - Permite añadir intervalos de confianza a las diferencias entre modelo y observación

$$t = \left(\frac{(n-1)MBD^2}{RMSD^2 - MBD^2} \right)^{1/2}$$

- d_1: Índice de concordancia de Willmott.
  - Limitado entre 0 (ausencia de concordancia) y 1 (concordancia total).
  - Robusto frente a *outliers*.

$$d_1 = 1 - \frac{\sum_{i=1}^{n} |m_i - o_i|}{\sum_{i=1}^{n} \left(\left|m_i - \overline{\mathbf{O}}\right| + \left|o_i - \overline{\mathbf{O}}\right| \right)}$$

Correlación

El coeficiente de correlación entre dos conjuntos de datos es una medida numérica de la relación **lineal** entre los dos conjuntos (si la relación no es lineal, este coeficiente no sirve):

$$r = \frac{1}{n-1} \cdot \sum_{i=1}^{n} \left(\frac{o_i - \overline{\mathbf{O}}}{\sigma_{\mathbf{O}}} \right) \cdot \left(\frac{m_i - \overline{\mathbf{M}}}{\sigma_{\mathbf{M}}} \right)$$

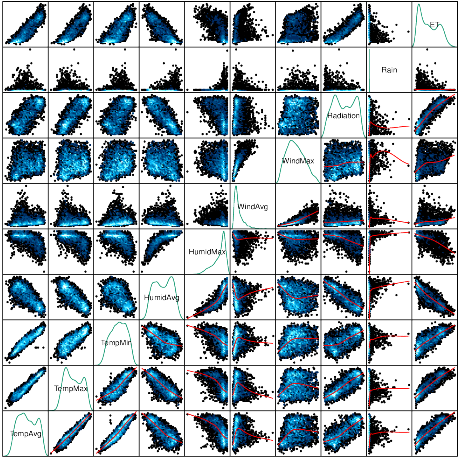

Diagramas de Taylor

- Desarrollando $\sigma^2_{\mathbf{D}}$ y teniendo en cuenta la definición de r:

$$\sigma^2_{\mathbf{D}} = \sigma^2_{\mathbf{O}} + \sigma^2_{\mathbf{M}} - 2 \cdot \sigma_{\mathbf{O}} \cdot \sigma_{\mathbf{M}} \cdot r$$

- Esta relación es semejante a la ley de los cosenos (c, a, b son lados de un triángulo y ϕ es el ángulo opuesto al lado c):

$$c^2 = a^2 + b^2 - 2 \cdot a \cdot b \cos \phi$$

Diagramas de Taylor

$$\sigma_{\mathbf{D}}^2 = \sigma_{\mathbf{O}}^2 + \sigma_{\mathbf{M}}^2 - 2 \cdot \sigma_{\mathbf{O}} \cdot \sigma_{\mathbf{M}} \cdot r$$

- $\sigma_{\mathbf{D}}^2$: Distancia al origen
- $\sigma_{\mathbf{O}}^2$: Eje horizontal
- $\sigma_{\mathbf{M}}^2$: Eje vertical
- r: acimut

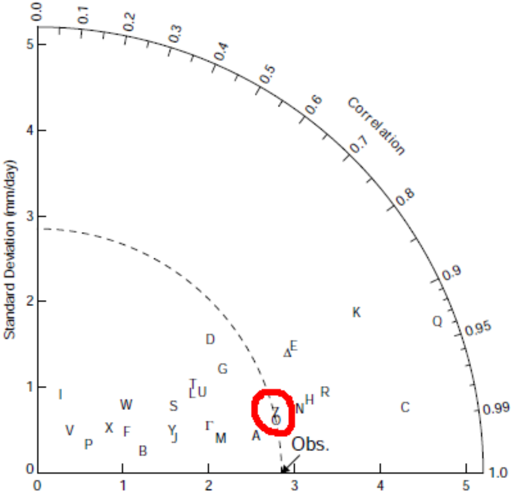

Target Diagram

- Emplea la relación entre $RMSD$, $\sigma_{\mathbf{D}}^2$, y $\overline{\mathbf{D}}$, normalizadas con $\sigma_{\mathbf{O}}$:

$$RMSD' = RMSD/\sigma_{\mathbf{O}}$$

$$\sigma'_{\mathbf{D}} = \sigma_{\mathbf{D}}/\sigma_{\mathbf{O}}$$

$$\overline{\mathbf{D}}' = \overline{\mathbf{D}}/\sigma_{\mathbf{O}}$$

$$RMSD'^2 = \sigma'^2_{\mathbf{D}} + \overline{\mathbf{D}}'^2$$

- Incorporan el signo de la diferencia entre desviaciones estándar del modelo y las observaciones.

$$sign_{\sigma} = sign(\sigma_{\mathbf{M}} - \sigma_{\mathbf{O}})$$

Target Diagram

- $\sigma'_{\mathbf{D}}$ (con signo): Eje horizontal
- $\overline{\mathbf{D}}'$: Eje vertical
- $RMSD'^2$: Distancia al origen

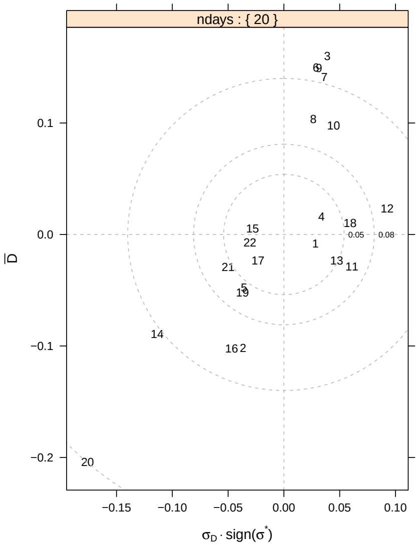

Planteamiento

- En un sistema compuesto por diferentes **unidades idénticas**, el funcionamiento de todas ellas debe ser el mismo.
- Los **elementos reales** presentan **diferencias** (tolerancia de potencia, pérdidas de dispersión, suciedad), de forma que el comportamiento de cada unidad se desviará del comportamiento promedio.
- Si **no hay problemas de funcionamiento**, estas desviaciones no superarán un umbral determinado (**coherencia estadística**).
- Un análisis estadístico del funcionamiento del conjunto puede **identificar una unidad defectuosa** como aquella que se aparta significativamente del comportamiento promedio.

Coherencia estadística

- Una medida puede ser etiquetada como *outlier* si es poco probable que pertenezca a la misma distribución que el conjunto.
- En estadística hay métodos diversos para realizar este análisis:
  - Métodos gráficos
  - Teorema de Chebyshev.
  - Criterios de Pierce y Chauvenet
- Los criterios de Pierce y Chauvenet asumen **distribución gaussiana** (aceptable en nuestro contexto) y son **simples de implementar**, particularmente Chauvenet.

Método de Chauvenet

Una medida es un *outlier* si la probabilidad de obtener su desviación respecto de la media es inferior al inverso de 2 veces el número de elementos en el conjunto.

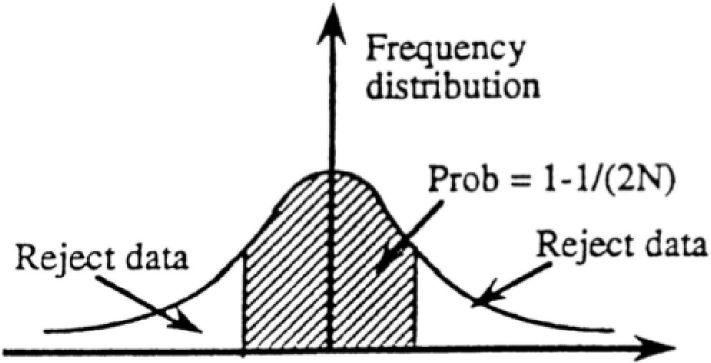

Método de Chauvenet

1. Supongamos un SFV compuesto por N unidades idénticas.
2. Sea $Y_{f,i}$ la medida de **productividad diaria** de una de esas unidades.
3. Se calcula la **media**, $\overline{Y}_f$, y la **desviación estándar**, σ_{Y_f}, del **conjunto**.
4. Se calcula la **distancia estadística** de cada unidad respecto del sistema total:

$$d_i = \frac{Y_{f,i} - \overline{Y}_f}{\sigma_{Y_f}}$$

5. En una distribución gaussiana, se calcula la distancia estadística equivalente a la probabilidad límite de Chauvenet, $1/2N$, teniendo en cuenta que hay dos colas.
6. Aquellas observaciones que superan la distancia son **marcadas como outliers**.

Método de Chauvenet

- Por ejemplo, para un sistema de 10 unidades, la probabilidad es $1/20$.
- A cada cola le corresponde la mitad, $1/40 = 0.025$.
- Por tanto, el límite es $d_{max} = -1.9599$ (cola izquierda, valores por debajo del conjunto).

$$d_i = \frac{Y_{f,i} - \overline{Y}_f}{\sigma_{Y_f}}$$

$$|d_i| > |d_{max}|$$

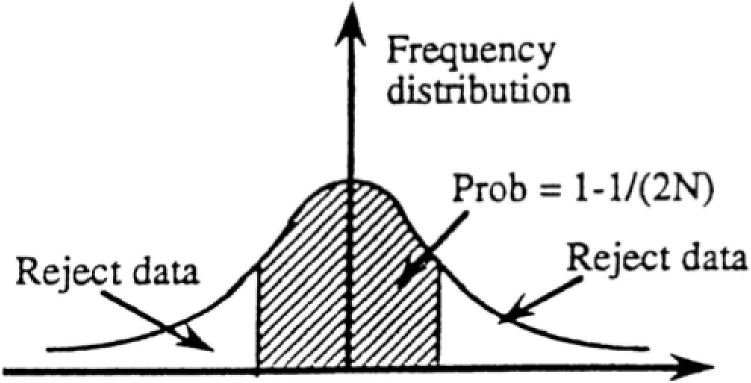

Métodos gráficos

- Sea $Y_{f,i}(t)$ la serie temporal de la productividad diaria de **una unidad** del SFV.
- Sea $\widetilde{Y}_f(t)$ la serie temporal de la **mediana** de la productividad diaria del SFV **completo**.
- Tomando $\widetilde{Y}_f(t)$ como modelo o referencia, podemos emplear los diagramas de Taylor y Target para detectar unidades defectuosas durante períodos de tiempo.